


Loukas Benazet



Fruits!



OPENCLASSROOMS

Problématique

Fruits! : Start-up

Objectif : Création d'une application mobile permettant de reconnaître le nom d'un fruit pris en photo


Mission : Compléter un notebook possédant des scripts d'architecture Big Data créés par un alternant

Données : 22688 images (100p X 100p) + 131 classes (labels)



Fruits!

Images



Fruits!

Pastèque
(157 images)



Ananas
(166 images)



Orange
(160 images)



Cerise
(246 images)





01

Révolution Map/Reduce

Révolution Map/Reduce

Exemple Map/Reduce pour le “comptage de mots”

1. SPLIT

Sépare notre data en plusieurs sous-ensembles

2. MAP


Transforme la donnée en une paire (clé, valeur)

3. SHUFFLE and SORT

Regroupe et trie par clé

4. REDUCE

Agrège les résultats et renvoie pour chaque clé une valeur unique



Révolution Map/Reduce

Hadoop 1.0 (2011)

- **Data locality** : Optimisation des transferts disques et réseaux en limitant les déplacements de données
- **Scalability** : Permet d'adapter la puissance au besoin
- **Embracing failure** : Doit avoir une tolérance aux pannes
- **Architecture** : HDFS (Hadoop Distributed File System) + MapReduce
- **Language** : Java (Autres langages avec Hadoop Streaming)

Révolution Map/Reduce

(Hadoop Distributed File System)

Hadoop 1.0 (2011) – HDFS

- **Name Node**


Stocke la localisation de chaque bloc dans le cluster

- **Secondary Name node**

Node de secours en cas de défaillance du nœud maître

- **Data node**

Gèrent les opérations de stockage (création, suppression et réplication de blocs)



Révolution Map/Reduce


Hadoop 1.0 (2011) – Map/Reduce

- **Job Tracker**

Orchestre les traitements et s'assure du bon déroulement des tâches (heartbeat)


- **Task Tracker**

Unité de calcul du cluster



Révolution Map/Reduce

Hadoop 2.0 (2012)



YARN (Yet Another Resource Negotiator)

Permet que des tâches autres que Map/Reduce puissent s'effectuer

Révolution Map/Reduce

Spark (2014)

Spark est un framework qui tend à corriger les limites de Hadoop 2.0

- **Vitesse** : Spark utilise la RAM (~100X plus rapide que sur le disque dur)
- **Adapté au machine learning** : Grâce aux packages SQL, MLlib
- **Plus facile** : Grâce aux abstractions RDD + DataFrames Spark
- **Meilleure compatibilité** : Spark marche avec n'importe quel type de BDD

Révolution Map/Reduce


Spark (2014) - Architecture

Cluster manager : Instancie les différents **workers**

Workers : Instancient un **executor**

Executors : Chargés d'exécuter les différentes tâches de calculs

Driver : Chargé de répartir les tâches sur les différents **executors**



Révolution Map/Reduce


Spark (2014) - RDD (Resilient Distributed Datasets)

RDD = Pointeur vers un fichier

Transformation : Permet de passer d'un RDD à un autre

Lazy evaluator : L'évaluation s'effectue uniquement après une action

Resilient : Un RDD peut être régénéré à partir de ses RDD parents



Exemple de DAG (Directed Acrylic Graph)

02

**Environnement
Big Data
(IAM / S3 / EMR)**



Environnement Big Data

IAAS ? PAAS ?

IAAS (Infrastructure AS A Service)

Les serveurs sont vierges

On doit installer nous-mêmes tous les outils pour notre script (Spark, Java, Python, Jupyter...)

Inconvénient : Chronophage

PAAS (Platform AS A Service)

Les Frameworks importants sont déjà installés

Les patches de sécurité sont automatiquement mis à jour

Plus facile de cloner ses clusters

Avantage : Rapide

La solution PAAS est adaptée pour ce projet avec AWS

Environnement Big Data

Autorisations Utilisateur

IAM (Identity and Access Management)

Tableau de bord IAM [Infos](#)

Recommandations de sécurité 2

 **Ajouter la MFA pour l'utilisateur racine**
Ajouter la MFA pour l'utilisateur root – Activez l'Authentification multifactorielle (MFA) pour l'utilisateur root afin d'améliorer la sécurité de ce compte.

[Ajouter la MFA](#)

 **Désactiver ou supprimer les clés d'accès pour l'utilisateur racine**
Désactivez ou supprimez les clés d'accès de l'utilisateur racine et utilisez plutôt les clés d'accès attachées à un utilisateur IAM pour renforcer la sécurité.

[Gérer les clés d'accès](#)

Compte AWS

ID de compte
 058264389557

Alias de compte
[Créer](#)

URL de connexion pour les utilisateurs IAM de ce compte
 <https://058264389557.signin.aws.amazon.com/console>

Ressources IAM

Ressources de ce compte AWS

Groupes de personnes	Personnes	Rôles	Politiques	Fournisseurs d'identité
0	0	25	22	0

Quick Links

[Mes autorisations de sécurité](#)

Gérez vos clés d'accès, l'authentification multi-facteur (MFA) et autres informations d'identification.

Autorisations : Tout type de manipulation dans les buckets S3

Environnement Big Data

Configuration AWS



IAM (Identity and Access Management)

▼ **Configuration de sécurité et paire de clés EC2** [Info](#)
Choisissez une configuration de sécurité ou créez-en une nouvelle que vous pourrez réutiliser avec d'autres clusters.

Configuration de sécurité
Sélectionnez les paramètres de chiffrement, d'authentification, d'autorisation et de service de métadonnées d'instance de votre cluster.

[Parcourir](#) [Créer une configuration de sécurité](#)

Paire de clés Amazon EC2 pour SSH sur le cluster [Info](#)

[Parcourir](#) [Créer une paire de clés](#)

Paire de clés : Permet de sécuriser l'accès à la connexion Utilisateur

Eu-west-3 : Serveurs à Paris -> Respecte le RGPD

RGPD : Règlement Général sur la Protection des Données (serveurs en Europe)

Environnement Big Data

aws S3 (Simple Storage Service)

p8-data-lb Info

Objets | Propriétés | Autorisations | Métriques | Gestion | Points

Objets (5) Info

[Copier l'URI S3](#) [Copier l'URL](#) [Télécharger](#) [Ouvrir](#)

[Actions](#) [Créer un dossier](#) [Charger](#)

Les objets sont les entités fondamentales stockées dans Amazon S3. Vous pouvez utiliser l'[inventaire Amazon S3](#) pour obtenir une liste de tous les objets de votre compartiment. Pour que d'autres personnes puissent accéder à vos objets, vous devez leur accorder explicitement des autorisations. [En savoir plus](#)

Rechercher des objets en fonction du préfixe

☐	Nom	Type	Dernière modification	Taille	Classe de stockage
☐	bootstrap-emr.sh	sh	11 Dec 2024 04:10:32 PM GMT	382.0 o	Standard
☐	jupyter/	Dossier	-	-	-
☐	Results_PCA/	Dossier	-	-	-
☐	Results/	Dossier	-	-	-
☐	Test/	Dossier	-	-	-

Test/ [Copier l'URI S3](#)

Objets | Propriétés

Objets (131) Info

[Copier l'URI S3](#) [Copier l'URL](#) [Télécharger](#) [Ouvrir](#) [Supprimer](#) [Actions](#) [Créer un dossier](#) [Charger](#)

Les objets sont les entités fondamentales stockées dans Amazon S3. Vous pouvez utiliser l'[inventaire Amazon S3](#) pour obtenir une liste de tous les objets de votre compartiment. Pour que d'autres personnes puissent accéder à vos objets, vous devez leur accorder explicitement des autorisations. [En savoir plus](#)

Rechercher des objets en fonction du préfixe

☐	Nom	Type	Dernière modification	Taille	Classe de stockage
☐	Apple Braeburn/	Dossier	-	-	-
☐	Apple Crimson Snow/	Dossier	-	-	-
☐	Apple Golden 1/	Dossier	-	-	-
☐	Apple Golden 2/	Dossier	-	-	-

Environnement Big Data

Frameworks à choisir



TensorFlow

Pour utiliser un modèle de classification d'images

Spark

Pour utiliser un kernel PySpark (calculs distribués)

JupyterHub

Pour manipuler des Notebooks directement chez AWS

▼ Nom et applications - [requis](#) [Info](#)

Donnez un nom à votre cluster et choisissez les applications que vous voulez y installer.

Nom

P8_Fruits

Version Amazon EMR [Info](#)

Une version contient un ensemble d'applications susceptibles d'être installées sur votre cluster.

emr-7.5.0

Offre d'applications

 Spark Interactive	 Core Hadoop	 Flink	 HBase	 Presto	 Trino	 Custom
--------------------------	--------------------	-----------	-----------	------------	-----------	------------

- | | | |
|---|---|--|
| ☐ AmazonCloudWatchAgent 1.300032.2 | ☐ Flink 1.19.1 | ☐ HBase 2.5.10 |
| ☐ HCatalog 3.1.3 | ☐ Hadoop 3.4.0 | ☐ Hive 3.1.3 |
| ☐ Hue 4.11.0 | ☐ JupyterEnterpriseGateway 2.6.0 | ☒ JupyterHub 1.5.0 |
| ☐ Livy 0.8.0 | ☐ Oozie 5.2.1 | ☐ Phoenix 5.2.0 |
| ☐ Pig 0.17.0 | ☐ Presto 0.287 | ☒ Spark 3.5.2 |
| ☒ TensorFlow 2.16.1 | ☐ Tez 0.10.2 | ☐ Trino 446 |
| ☐ Zeppelin 0.11.1 | ☐ ZooKeeper 3.9.2 | |

Environnement Big Data

Bootstrapping

 **EMR (Elastic MapReduce)**

D'autres packages doivent être installés pour le bon fonctionnement des scripts

wheel : Accélère l'installation des packages Python

pillow : Bibliothèque de traitement d'image en Python

pyarrow : Lit les fichiers parquets et les convertit en Dataframe

boto3 + s3fs + fsspec : Permettent d'interagir avec Amazon S3

matplotlib : Permet de visualiser les données sur Python

Environnement Big Data

Machines



1 Unité Primaire (Master)

Exécute YARN et HDFS Name Node

1 Unité principale (Core)

Exécute le HDFS Data Node et sert aussi d'unité de tâche

X Unités de Tâche (Task)

Effectuent uniquement les tâches de calcul parallèle sur les données

Groupes d'instances (6)

Info

Résilier l'instance

Redimensionner le groupe d'instances

Ajouter un groupe d'instances de tâches

Avec la configuration des groupes d'instances, chaque type de nœud est constitué du même type d'instance et de la même option d'achat d'instances : à la demande ou Spot.

Rechercher des instances par ...

Rechercher des ressources par ID ou type ; ou rechercher le texte

<

1

>

	Type et nom	ID	Statut Motif du dernier chan	Instances	Option d'achat et ...
☐	Primaire	lg-2CFY0I7F8E7CS	En cours d'exécution	3	À la demande
☐	Principal (Unité principale)	lg-1CGP3KMWN66NO	En cours d'exécution	1	À la demande
☐	Tâche (Tâche - 3)	lg-3CJ2QY41PSM9J	Interrompu The request to create the EM	0 (1 deman...	À la demande
☐	Tâche (Tâche - 1)	lg-3OPZAXLP6BOCR	Interrompu The request to create the EM	0 (1 deman...	À la demande
☐	Tâche (Tâche - 4)	lg-2AW1VHZYB7M5L	Interrompu The request to create the EM	0 (1 deman...	À la demande
☐	Tâche (Tâche - 2)	lg-1QARTIOFFZXAF	Interrompu The request to create the EM	0 (1 deman...	À la demande

Environnement Big Data

Tunnel SSH

 **EMR (Elastic MapReduce)**

Pour pouvoir ouvrir JupyterHub + SparkUI, un tunnel SSH doit être créé

- On crée une clé SSH (à utiliser lors de la création d'un cluster)
- On la sécurise afin que seul l'Administrateur local puisse s'en servir
- On autorise le tunnel SSH (port 22) dans AWS
- Une fois le cluster créé, on établit la connexion SSH à partir de bash
- Pour Mozilla Firefox, l'extension FoxyProxy permet d'utiliser ce tunnel

03

Chaîne de traitement des images




Chaîne de traitement des images

SparkUI

Aperçu de la chaîne entière de traitement

Spark Jobs (?)

User: livy
Total Uptime: 27 min
Scheduling Mode: FIFO
Completed Stages: 64
Skipped Stages: 1
Event Timeline
☐ Enable zooming



Chaîne de traitement des images

Stage 3

DAG SparkUI pour l'extraction des features

Scan binaryFile


Lit le fichier binaire dérivé des images

WholeStageCodegen

Optimisation Spark SQL. Il combine plusieurs opérations (filter, map...) en une seule fonction pour améliorer les performances et réduire la surcharge

ShuffleQueryStage

Réorganise les données à travers les partitions pour se préparer à l'algorithme Reduce (Stage 5)



Chaîne de traitement des images

Stage 3

Ex. de visualisation pour l'extraction des features



Summary Metrics for 709 Completed Tasks

Chaîne de traitement des images

Enregistrement des résultats

Stage 5

Results/

 Copier l'URI S3

Objets

Propriétés

Objets (21) Info



 Copier l'URI S3

 Copier l'URL

 Télécharger

Ouvrir 

Supprimer

Actions 

Créer un dossier

 Charger

Les objets sont les entités fondamentales stockées dans Amazon S3. Vous pouvez utiliser l'[Inventaire Amazon S3](#) pour obtenir une liste de tous les objets de votre compartiment. Pour que d'autres personnes puissent accéder à vos objets, vous devez leur accorder explicitement des autorisations. [En savoir plus](#)

 Rechercher des objets en fonction du préfixe


< 1 > 

☐	Nom	Type	Dernière modification	Taille	Classe de stockage
☐	 _SUCCESS	-	25 Dec 2024 08:15:03 PM GMT	0 o	Standard
☐	 part-00000-e3c607ab-c6c3-486d-87e6-d890878202d0-c000.snappy.parquet	parquet	25 Dec 2024 08:09:40 PM GMT	4.2 Mo	Standard
☐	 part-00001-e3c607ab-c6c3-486d-87e6-d890878202d0-c000.snappy.parquet	parquet	25 Dec 2024 08:09:40 PM GMT	4.2 Mo	Standard
☐	 part-00002-e3c607ab-c6c3-486d-87e6-d890878202d0-c000.snappy.parquet	parquet	25 Dec 2024 08:10:16 PM GMT	4.2 Mo	Standard

22688 images / 1280 features par image / 20 parquets

Chaîne de traitement des images

CP expliquant 80% de la variance



80 composantes principales
expliquent 80% de la variance

ACP effectuée avec PySpark ML
et SQL

Chaîne de traitement des images

Résultats finaux

path	label	features	pcaFeatures
s3://p8-data-lb/T...	Watermelon	[0.12482018, 0.02...	[-2.8237825964401...
s3://p8-data-lb/T...	Watermelon	[1.0893836, 0.075...	[-3.4354594854397...
s3://p8-data-lb/T...	Watermelon	[1.208744, 0.0030...	[-3.1259901957171...
s3://p8-data-lb/T...	Pineapple Mini	[0.0, 5.0685105, ...	[-6.2244896320455...
s3://p8-data-lb/T...	Pineapple Mini	[0.0, 4.5876484, ...	[-4.7361750317898...
s3://p8-data-lb/T...	Pineapple Mini	[0.0, 4.519898, 0...	[-6.4304549845165...
s3://p8-data-lb/T...	Watermelon	[0.77535725, 0.24...	[-3.3317783936249...
s3://p8-data-lb/T...	Pineapple Mini	[0.0, 4.407875, 0...	[-5.5666667385475...
s3://p8-data-lb/T...	Pineapple Mini	[0.0, 4.459133, 0...	[-5.5120426790383...
s3://p8-data-lb/T...	Watermelon	[0.18416415, 0.0...	[-4.7095444604679...
s3://p8-data-lb/T...	Watermelon	[0.012865087, 0.2...	[-1.9200305572885...
s3://p8-data-lb/T...	Watermelon	[0.0, 0.22407937, ...	[-3.3147596180142...
s3://p8-data-lb/T...	Watermelon	[0.119276375, 0.0...	[-3.4228057734055...
s3://p8-data-lb/T...	Watermelon	[0.0, 0.22032487, ...	[-2.8165704058987...
s3://p8-data-lb/T...	Cauliflower	[0.0, 0.8690344, ...	[-4.2588866196197...
s3://p8-data-lb/T...	Cauliflower	[0.0, 1.3841038, ...	[-4.4765762545420...
s3://p8-data-lb/T...	Raspberry	[0.32900378, 0.59...	[-1.9229995562511...
s3://p8-data-lb/T...	Cauliflower	[0.024995342, 0.3...	[-4.6125013080440...
s3://p8-data-lb/T...	Raspberry	[0.03869541, 0.20...	[-0.6948615904381...
s3://p8-data-lb/T...	Raspberry	[0.24571064, 0.43...	[-1.9875168084382...

only showing top 20 rows

Extraction des features

22688 images

ACP

11344 features

L'ACP requiert beaucoup de mémoire RAM. Pour remédier à ce problème lié au volume de données, il serait nécessaire d'augmenter le nombre de machines.

Chaîne de traitement des images

Résultats finaux

Results_PCA/

 Copier l'URI S3

Objets

Propriétés

Objets (3) [Info](#)



 Copier l'URI S3

 Copier l'URL

 Télécharger

Ouvrir 

Supprimer

Actions ▼

Créer un dossier

 Charger

Les objets sont les entités fondamentales stockées dans Amazon S3. Vous pouvez utiliser [l'inventaire Amazon S3](#) pour obtenir une liste de tous les objets de votre compartiment. Pour que d'autres personnes puissent accéder à vos objets, vous devez leur accorder explicitement des autorisations. [En savoir plus](#)

 Rechercher des objets en fonction du préfix

< 1 > 

☐	Nom	Type	Dernière modification	Taille	Classe de stockage
☐	 _SUCCESS	-	25 Dec 2024 11:06:10 PM GMT	0 o	Standard
☐	 part-0000-e1dc0a09-718e-44a2-980d-0f9e4d9d4c45-c000.snappy.parquet	parquet	25 Dec 2024 11:06:08 PM GMT	48.7 Mo	Standard
☐	 part-00001-e1dc0a09-718e-44a2-980d-0f9e4d9d4c45-c000.snappy.parquet	parquet	25 Dec 2024 11:06:09 PM GMT	48.5 Mo	Standard

04

Démonstration script PySpark sur le Cloud

Lien EMR AWS (Serveurs sur Paris)

<https://eu-west-3.console.aws.amazon.com/emr/home?region=eu-west-3#/clusters>

Conclusion

Synthèse

- **Map/Reduce** à permis la **parallélisation des calculs** dans plusieurs machines
- Hadoop fut le premier framework à se servir de Map/Reduce
- **Spark** est le framework à utiliser pour le **ML** et le data science
- **AWS** (IAM + S3 + EMR) nous propose un **service big data** complet
- **SparkUI** nous permet de **visualiser** les détails des calculs distribués
- Une extraction de features ainsi qu'une réduction ACP fut appliquée avec Spark
- L'enregistrement en parquets nous permet de garder ces résultats dans le S3

Perspectives

- Modèles de classification : Regressions, Random Forest, LightGBM,...
- Visualisation : t-SNE en 2D ou 3D
- Amélioration des performances

Merci

Place aux questions :)